

Computação de Alto Desempenho

Jorge Augusto Salgado Salhani

nº USP: 8927418

Setembro, 2026

1 Modulo 3

1. A avaliação de desempenho de aplicações paralelas não pode considerar apenas o tempo de resposta de um algoritmo paralelo sem considerar fatores como: custos extra associados, tamanho da plataforma e carga de trabalho. Explique como isso é feito.

[SOLUÇÃO]

A avaliação de desempenho de aplicações pode ser feita em termos do tempo de resposta em relação a sua versão paralela e número de processadores (caso speedup e eficiência), em relação ao overhead (tempo de comunicação entre processos, sincronização e acesso à memória), em relação à carga de trabalho (carga fixa ou tempo fixo)

2. Defina speedup.

[SOLUÇÃO]

Speedup mede o ganho de velocidade relativo de p processadores em relação ao tempo de processamento de $p = 1$ processador

$$S_{p'} = T_{p=1} / T_{p=p'}$$

3. Uma aplicação sequencial tem uma carga de trabalho $W_{seq} = n^2 + n^7 + n$ onde n é o número de itens a serem processados. Essa aplicação foi paralelizada em dois diferentes algoritmos usando p processadores, sendo:

$$\text{Alg-01 : } W_{par1} = n^2 + (n^7/p) + n$$

$$\text{Alg-02 : } W_{par2} = (n^2/p) + (n^7/p) + n + (2 \times T_{comm} \times p)$$

Determine o speedup absoluto desses dois algoritmos para diferentes valores de n (10, 100, 1000) e para diferentes valores de p (16, 64, 256). $T_{comm} = n \times 10^6$

[SOLUÇÃO]

O speedup absoluto é dado pela razão entre o tempo por carga sequencial W_{seq} e o tempo por carga paralela de cada algoritmo W_{par}

$$S_1 = \frac{W_{seq}}{W_{par1}} = \frac{n^2 + n^7 + n}{n^2 + (n^7/p) + n}$$
$$S_2 = \frac{W_{seq}}{W_{par2}} = \frac{n^2 + n^7 + n}{(n^2/p) + (n^7/p) + n + (2np10^6)}$$

4. Defina eficiência.

Eficiência indica quanto da capacidade paralela está sendo efetivamente aproveitada. É dada pela razão entre o speedup por número de processadores

$$E_p = \frac{S_p}{p} = \frac{T_{p'=1}}{pT_{p'=p}}$$

5. Qual a eficiência dos algoritmos da questão 3.?

6. Uma rede tem um custo $t_s = 143\mu s$ e $T_w = 8.5ns$. Uma aplicação paralela transmite $2p$ mensagens de $(4000k/p)$ Bytes a diferentes processos replicas hospedados em p processadores e recebe destes p processos o retorno de p mensagens com 4 bytes cada. Qual o T_{comm} desta aplicação?

[SOLUÇÃO]

O tempo total de comunicação é dado por

$$T = ct_s + mt_w$$

Com t_s tempo de startup (inicialização) por c mensagens, t_w tempo de transferência de uma word (palavra, ou menor unidade de informação) m tamanho da palavra.

Sendo o tamanho de dados enviados: $m = 2p \times 4000kB/p = 8000kB$, assim o tempo de envio de dados é

$$T_{envio} = (2p) \times t_s + (8000kB) \times t_w$$

Sendo o recebimento de $m = p \times 4B$, temos

$$T_{retorno} = p \times t_s + (4p) \times t_w$$

Como o tempo total de comunicação é $T_{comm} = T_{envio} + T_{retorno}$, temos

$$T_{comm} = 2pt_s + pt_s + 8000(10^3)t_w + 4pt_w$$

7. Qual a diferença entre tempo de execução e tempo de resposta de uma aplicação paralela?

[SOLUÇÃO]

Tempo de execução é o intervalo de tempo em que processadores passam computando a aplicação, com instruções de CPU, acesso à memória e overheads de sincronização.

$$T_{exec} = T_{\text{fim do último thread}} - T_{\text{início do primeiro thread}}$$

Tempo de resposta é o intervalo de tempo desde o recebimento do pedido de execução da aplicação pelo usuário até a entrega do resultado final, com tempo de execução, tempo de fila, overheads do SO, acessos à rede e disco

$$T_{resp} = T_{\text{entrega do resultado}} - T_{\text{recebimento do pedido}}$$

8. O que é T_{idle} de uma aplicação paralela?

[SOLUÇÃO]

Tempo de ociosidade é a soma do tempo em que todos os processadores/threads permanecem inativos durante a execução do programa, com barreiras de sincronização, bloqueio por comunicação (IO e rede). Junto com o tempo de inicialização e de comunicação estabelece o tempo de overhead de uma aplicação

$$T_{overhead} = T_{comm} + T_{idle} + T_{setup}$$

9. O que determina a Lei de Amdahl?

[SOLUÇÃO]

Determina o limite teórico máximo de ganho de velocidade (speedup) que uma aplicação pode alcançar ao ser paralelizada mantendo o tamanho do problema fixo.

Assim, sendo f fração do código estritamente sequencial, $(1 - f)$ fração do código paralelizada, p número de processadores, temos

$$S_p = \frac{1}{f + \frac{1-f}{p}}$$

Para infinitos processadores $p \rightarrow \infty$, temos $S_p = 1/f$, ou seja, o número de execuções da aplicação por unidade de tempo é igual ao número de execuções da parte sequencial da aplicação por unidade de tempo.

10. O algoritmo sequencial X tem um tempo de resposta de 15s e, destes, 0.03s não puderam ser paralelizados na versão paralela do mesmo. Segundo Amdahl, qual o Speedup máximo deste algoritmo, sem considerar qualquer sobrecarga?

[SOLUÇÃO]

Sendo $T_1 = 15s$ tempo total do algoritmo sequencial. $T_{seq} = 0.03s$ tempo da fração não paralelizada. Assim temos

$$f = \frac{T_{seq}}{T_1} = \frac{0.03}{15} = 0.002$$

$$S_{p_{max}} = \frac{1}{f} = \frac{1}{0.002} = 1/2 \times 10^3 s$$

11. Você precisa analisar o desempenho de uma aplicação paralela qualquer, em termos de tempo de resposta. Onde você colocaria a coleta de tempo no código fonte? Quantas execuções faria para cada dado de entrada? O que mudaria nos dados de entrada?

Coleta de tempo imediatamente antes de iniciar a região paralela e imediatamente após a sincronização dos threads, sendo que a leitura de dados de entrada deva ser realizada antes da paralelização.

Em relação aos dados de entrada, são necessários dois cenários. Uma carga pequena, para avaliar os efeitos de inicialização e criação de threads; Outra com carga média e grande, para que o efeito da fração sequencial do código seja reduzido.

Já em relação ao número de execuções, é importante realizar ao menos 10 execuções independentes, para que sejam minorizados ruídos de execuções muito rápidas ou muito lentas.